

支持向量机（SVM）理论分析

矜持

2026 年 5 月 23 日

目录

1	SVM 算法	3
1.1	线性可分	3
1.2	线性不可分	4
1.3	一个简单的例子	6
1.3.1	等式约束	6
1.3.2	不等式约束	8
2	从拉格朗日方法到对偶问题	9
2.1	广义拉格朗日的极小极大问题	10
2.2	广义拉格朗日的极大极小问题	10
2.3	弱对偶条件与强对偶条件	11
2.4	KKT 条件	12
2.5	强对偶与 KKT 条件的联系	12
2.6	对对偶问题的进一步理解	13
2.7	求解对偶问题	14
3	从对偶问题重新回到原问题	16
3.1	回到原问题	17
3.2	一个看似可行的思路	17
3.2.1	思路一	18
3.2.2	思路二	18
3.3	关于学习率和收敛性	19
3.4	关于两个投影方法的比较	19
3.5	投影公式的简单证明	20
4	引理一：线性变换的收缩性	22

5	投影梯度法的收敛性与稳定点严格证明	24
5.1	第一部分：全局非扩张性证明（Non-expansiveness）	24
5.1.1	1. 梯度步的距离变化（引用引理一）	24
5.1.2	2. 等式投影步的距离变化	25
5.1.3	3. 非负截断步的分量对比	25
5.1.4	4. 复合算子的全局非扩张结论	26
5.2	第二部分：稳定点（不动点） α^* 的存在性定理	26
5.3	第三部分：算法收敛性的严格证明（存疑）	26

1 SVM 算法

SVM 是 Support Vector Machine 的简称，即支撑向量机。在传统感知机算法中，假设存在线性可分的超平面，那么我们可以知道通过有限次操作，最后我们一定可以得到这个超平面。

但这种方法处理起来由两个弊端。第一，我们得到的超平面是不唯一的，这受到数据本身的影响以及随机数初始化的影响。即使得到了超平面，超平面直接亦有优劣之分。第二，数据如果线性不可分，那么就很难办了。我们根本得不到这个结果。而这又包括两种情形

- 数据不能用超平面分离，但是哪些不可分离的点是可以认为是误差
- 数据本身的性质使得他不存在用超平面直接分离，例如异或分类问题。

因此对以上两种情况。我们要加以讨论。

我们先处理第一种类型。

1.1 线性可分

所谓线性可分，其实就是和感知机问题中的假设一样，数据能用一个超平面分离。这里我们假设数据集是 T ，超平面的参数 w 和 b 。假设上述参数恰好可以分离样本点。

于是我们可以对某一个样本点关于这个超平面的参数定义距离。我们用 $|wx + b|$ 表示样本点 x 的距离，用 $wx + b$ 的符号指明其属于正类还是负类。我们知道样本 x_i ，类别 y_i ，并且在上面参数下是正确分类的，因此于是可以用

$$\hat{\gamma}_i = y_i(w \cdot x_i + b) \quad (1)$$

来表示函数间隔。类似的，我们可以用

$$\gamma_i = \frac{\hat{\gamma}_i}{\|w\|} = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \quad (2)$$

表示几何间隔。注意到 $\hat{\gamma} = \|w\| \cdot \gamma$ 我们的目标是最大化这个几何间隔的距离，也就是求解优化问题

$$\begin{aligned} \max_{w,b} \quad & \gamma \\ \text{s.t.} \quad & y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma \end{aligned} \quad (3)$$

这等价于

$$\begin{aligned} \max_{w,b} \quad & \frac{\hat{\gamma}}{\|w\|} \\ \text{s.t.} \quad & y_i (w \cdot x_i + b) \geq \hat{\gamma} \end{aligned} \quad (4)$$

这里我们会发现，函数间隔的取值实际上并不影响最终的解的结果，因为我们可以任意的缩放 w 和 b ，此时并不会对符号有所影响。正因此，我们可以固定函数间隔

$\hat{\gamma} = 1$ 。同时把求解 $\|w\|$ 的最大化问题转化为求解 $\frac{1}{2}\|w\|^2$ 的最小化问题，对于另一个不等式约束我们转化为标准约束的形式，于是我们可以把问题转化为

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2}\|w\|^2 \\ \text{s.t.} \quad & 1 - y_i(w \cdot x_i + b) \leq 0 \end{aligned} \quad (5)$$

这个就是凸二次规划问题。在已知线性可分的条件下，我们可以证明解的存在性和唯一性。

1.2 线性不可分

如果说是线性不可分的情形，我们需要引入软间隔。在前面我们的不等式约束是

$$1 - y_i(w \cdot x_i + b) \leq 0 \quad (6)$$

也就是

$$y_i(w \cdot x_i + b) \geq 1 \quad (7)$$

这里我们减弱一下，把他改成

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i \quad (8)$$

其中 ξ_i 我们叫做松弛变量，相当于放松了几何间隔的条件。同时，我们希望这个 ξ_i 能够尽可能的小，于是我们的目标函数就改为了

$$\min_{w,b,\xi} \quad \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i \quad (9)$$

这里的 C 是一个常数。我们希望在最小化间隔距离的同时，让这些松弛变量也尽可能的小。这就得到了线性不可分的凸二次规划问题

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & 1 - \xi_i - y_i(w \cdot x_i + b) \leq 0 \\ & -\xi_i \leq 0 \end{aligned} \quad (10)$$

接下来的任务是处理上面两个凸二次优化问题。

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2}\|w\|^2 \\ \text{s.t.} \quad & 1 - y_i(w \cdot x_i + b) \leq 0 \end{aligned} \quad (11)$$

以及

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & 1 - \xi_i - y_i(w \cdot x_i + b) \leq 0 \\ & -\xi_i \leq 0 \end{aligned} \quad (12)$$

如何用计算机进行求解呢？我们先从简单的问题开始。

在数分中我们学过 Lagrange 方法，他是用来求解函数的极值的，但仅限于等式约束。对于不等式约束的情形稍微复杂一点。

我们考虑一般的凸二次规划问题

$$\begin{aligned} \min_x \quad & f(x) \quad \text{目标函数} \\ \text{s.t.} \quad & g(x) = 0 \quad \text{等式约束} \\ & h(x) \leq 0 \quad \text{不等式约束} \end{aligned} \quad (13)$$

对于等式约束问题，我们在数学分析中已经接触过 Lagrange 方法。

例如对于问题

$$\min_x f(x) \quad (14)$$

并且满足约束

$$g(x) = 0 \quad (15)$$

这个约束条件其实就是可行域。我们可以构造拉格朗日函数

$$L(x, \beta) = f(x) + \beta g(x) \quad (16)$$

怎么理解这个式子呢？

我们知道曲面中，过一点有无数条曲线，但是这些曲线在这一点的切向量一定都和曲线在该点的梯度（也就是法向量）垂直。（这是数学分析中的一个结论）切向量构成的空间是切空间。在三维空间中，这个切空间恰好就是一个平面。

因为函数的梯度指明了函数增长最快的一个方向。目标函数的梯度指明函数沿当前方向函数增加最快。约束条件的梯度指明函数下一时刻的只能沿着和梯度垂直的方向前行。如果目标函数和约束条件的梯度方向一致，说明在当前点处，可能是极值点。如果方向不一致，我们可以找到在当前约束条件下，约束条件的梯度在目标函数的梯度这两者是有夹角的，沿着这个投影的方向走，函数一定不会是极值点。正着走函数值变大，逆着走函数值变小。

由于函数的梯度和函数的增长方向一致，所以在可行域上，如果函数取到极值，其拉格朗日函数也取到极值这里的 β 我们称为拉格朗日乘子。

这种方法的核心思想其实是：

我们不再直接在约束曲面上寻找极值，而是把约束条件“加入”目标函数中。

如果某一个点满足极值条件，那么此时目标函数的梯度方向应该与约束曲面的法向量方向一致。因此我们有

$$\nabla f(x) + \beta \nabla g(x) = 0 \quad (17)$$

这也就是

$$\nabla_x L(x, \beta) = 0 \quad (18)$$

另一方面,

$$\nabla_{\beta} L(x, \beta) = g(x) = 0 \quad (19)$$

于是我们就得到了

$$\nabla_x L = 0, \nabla_{\beta} L = 0 \quad (20)$$

这给出了等式约束下的极值条件。

但对于 SVM 中的不等式约束问题, 例如

$$1 - y_i(w \cdot x_i + b) \leq 0 \quad (21)$$

情况会更加复杂。因为不等式约束并不一定总是“取到等号”。这是需要分情况讨论。

如果极值点在不等式的内部取到等号, 此时不等式对实际目标函数没有产生约束效果。

如果极值点在不等式的边界取到等号, 此时不等式是对实际目标函数有约束效果的, 并且这里对不等式的梯度方向也有要求。

也就是说, 我们可以引入参数 α 使得 $\alpha \cdot h(x) = 0$ 。当 $h(x) < 0$ 时, $\alpha = 0$, 不等式约束不起作用。当 $h(x) = 0$ 时, $\alpha \neq 0$, 不等式约束变为等式约束, 同时我们需要满足, 在 $h(x) = 0$ 上, 目标函数的梯度除了要和 ∇h 一致, 其实还要相反。因为我们实际上是允许 $h(x)$ 沿着 $h(x) < 0$ 的方向走的。于是我们就在拉格朗日函数中增加了新的一项。

$$L(x, \beta, \alpha) = f(x) + \beta g(x) + \alpha h(x) \quad (22)$$

其中 $\alpha \geq 0$ 。

我们要特别关注 $\alpha \neq 0$ 的情形。因为 $\alpha \neq 0$ 就说明了不等式约束弱化为了等式约束, 也就真的对目标函数实实在在起了作用。这在 SVM 中是很关键的, “支撑向量”就是专门命名这个不等式约束的。

1.3 一个简单的例子

我们可以用一个简单的例子理解等式约束和不等式约束。

考虑目标函数

$$f(x, y) = x^2 + y^2 \quad (23)$$

这个函数表示点 (x, y) 到原点的距离平方。它的等高线是一族以原点为中心的圆。

1.3.1 等式约束

现在我们加入约束

$$x + y - 1 = 0 \quad (24)$$

这表示我们只能在一条直线上移动。

于是问题变成:

在直线 $x + y = 1$ 上，寻找距离原点最近的点。

从几何上来看，我们实际上是在寻找：

与直线第一次“接触”的那个圆。

此时圆与直线会发生相切。

另一方面，

$$\nabla f(x, y) = (2x, 2y) \quad (25)$$

表示函数增长最快方向。


而约束函数

$$g(x, y) = x + y - 1 \quad (26)$$

满足

$$\nabla g(x, y) = (1, 1) \quad (27)$$

这是约束直线的法向量。具体可以参考下面这个示意图， A 是约束条件上的一个点。我们可以看到此时 f 的梯度方向和 g 的梯度方向不一致，因此 A 不可能是极值点。



当取到极值时，我们已经无法沿着约束直线继续减小函数值。因此目标函数的梯度在切空间上不能再有分量。

于是：

$$\nabla f(x, y) = \lambda \nabla g(x, y) \quad (28)$$

即

$$(2x, 2y) = \lambda(1, 1) \quad (29)$$

因此得到

$$x = y \quad (30)$$

再结合约束条件

$$x + y = 1 \quad (31)$$

得到

$$x = y = \frac{1}{2} \quad (32)$$

这就是约束条件下的极值点。

1.3.2 不等式约束

现在我们把约束改成

$$x + y - 1 \leq 0 \quad (33)$$

此时可行域不再是一条直线，而是一个半平面。

于是极值点可能出现两种情况：

- 极值点位于可行域内部
- 极值点位于可行域边界

如果极值点位于内部，那么约束实际上没有真正起作用。

例如：

$$\min x^2 + y^2 \quad (34)$$

在约束

$$x + y - 1 \leq 0 \quad (35)$$

下，原点 $(0, 0)$ 本身就满足约束。

因此最优点仍然是

$$(0, 0) \quad (36)$$

此时：

$$x + y - 1 = -1 < 0 \quad (37)$$

说明约束没有“卡住”最优解。

但如果目标函数不断试图向边界外移动，那么最终最优点就会落在边界上。这时不等式约束就退化成了等式约束。

因此对于不等式约束，我们需要额外引入条件

$$\alpha h(x) = 0 \quad (38)$$

这称为互补松弛条件（complementary slackness）。

它表示：

- 若 $h(x) < 0$ ，则 $\alpha = 0$
- 若 $\alpha > 0$ ，则必须有 $h(x) = 0$

这也正是 KKT 条件的核心思想。

2 从拉格朗日方法到对偶问题

前面我们已经构造了凸二次优化问题，包括

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & 1 - y_i(w \cdot x_i + b) \leq 0 \end{aligned} \quad (39)$$

以及

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & 1 - \xi_i - y_i(w \cdot x_i + b) \leq 0 \\ & -\xi_i \leq 0 \end{aligned} \quad (40)$$

考虑

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & 1 - y_i(w \cdot x_i + b) \leq 0 \end{aligned} \quad (41)$$

令 $c_i(x) = 1 - y_i(w \cdot x_i + b)$ 于是我们可以构造拉格朗日函数

$$\begin{aligned} L(w, \alpha) &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \alpha_i c_i(x) \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i (y_i w \cdot x_i + b) \end{aligned} \quad (42)$$

关于求解此类问题，我们考虑一般的情形。对优化问题

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0 \\ & c_j(x) \leq 0 \end{aligned} \quad (43)$$

引入相关的拉格朗日函数

$$L(x, \alpha, \beta) = f(x) + \sum_{i, \alpha_i \geq 0} \alpha_i c_i(x) + \sum_j \beta_j h_j(x) \quad (44)$$

直接求解该问题，我们知道极值点的必要条件要满足以下条件：

- $\nabla_x L = 0$ 并且 $\nabla_\beta L = 0$ ，其中后者本质上是等式约束
- 不等式约束的系数 $\alpha_i \geq 0$
- 目标函数的极值要么在不等式约束的边界上取到等号，也就是 $c_i(x) = 0$ ，此时 $\alpha_i > 0$ 。要么在不等式约束的内部取到等号，也就是 $c_i(x) < 0$ 。此时 $\alpha_i = 0$ 。不管是哪一种情形，我们都能得到 $\alpha_i c_i(x) = 0$ 。

但是这样求解，由于我们并不知道某个不等式是否对目标函数的极值产生了影响，因此需要对 α 的值进行讨论，过程非常复杂。那有什么简化的方法吗？

2.1 广义拉格朗日的极小极大问题

下面我们研究一个被称为广义拉格朗日的极小极大问题。我们延续上面的符号，考虑拉格朗日函数

$$L(x, \alpha, \beta) = f(x) + \sum_{i, \alpha_i \geq 0} \alpha_i c_i(x) + \sum_j \beta_j h_j(x) \quad (45)$$

定义

$$\theta_p(x) = \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) \quad (46)$$

如果 x 满足约束条件，即

$$c_i(x) \leq 0, \quad h_j(x) = 0 \quad (47)$$

由于 $\alpha_i \geq 0$ ，因此

$$L(x, \alpha, \beta) = f(x) + \sum_i \alpha_i c_i(x) \leq f(x) \quad (48)$$

当取 $\alpha_i = 0$ 时取等，因此

$$\theta_p(x) = \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) = f(x) \quad (49)$$

若 x 不满足约束条件，则或者 $c_i(x) > 0$ ，或者 $h_i(x) \neq 0$ ，两者都可以通过选取合适的参数 α 与 β 使得 $L(x, \alpha, \beta)$ 趋于正无穷。于是我们有

$$\theta_p(x) = \begin{cases} f(x) & x \text{ 符合约束} \\ +\infty & x \text{ 不符合约束} \end{cases} \quad (50)$$

从而我们对 f 求极小，等价于对 $\theta_p(x)$ 求极小。

上面我们对拉格朗日函数先对参数求极大值，再求极小，也就是

$$\min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) \quad (51)$$

我们把它称为广义拉格朗日的极小极大问题。他和原问题是等价的。我们令

$$p^* = \min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) = \min_x f(x) \quad (52)$$

为原问题的解。

上面的我们先取极小再取极大，如果我们交换一下这个顺序呢？情况会有什么变化呢？类似地，我们可以引入对偶问题。

2.2 广义拉格朗日的极大极小问题

定义

$$\theta_d(\alpha, \beta) = \min_x L(x, \alpha, \beta) \quad (53)$$

如果我们在这里考虑

$$\max_{\alpha, \beta, \alpha_i \geq 0} \theta_d(\alpha, \beta) \quad (54)$$

其实就是

$$\max_{\alpha, \beta, \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \quad (55)$$

令

$$d^* = \max_{\alpha, \beta, \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \quad (56)$$

是对偶问题的解。

我们把它称为广义拉格朗日的极大极小问题。可以看到这里与上面的

$$\min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) \quad (57)$$

在 $\min$ 与 $\max$ 的前后顺序上有所区别。我们下面对这两个式子进行讨论。

2.3 弱对偶条件与强对偶条件

假设 x^* 是某一个可行解，于是我们有 $c_i(x^*) \leq 0$, $h_j(x^*) = 0$ 。从而

$$\min_x L(x, \alpha, \beta) \leq L(x^*, \alpha, \beta) \leq f(x^*) \quad (58)$$

左边成立是显然的，右边是因为当 x^* 是某个可行解时，自然满足

$$\begin{aligned} L(x^*, \alpha, \beta) &= f(x^*) + \sum_{i, \alpha_i \geq 0} \alpha_i c_i(x^*) + \sum_j \beta_j h_j(x^*) \\ &= f(x^*) + \sum_{i, \alpha_i \geq 0} \alpha_i c_i(x^*) \\ &\leq f(x^*) \end{aligned} \quad (59)$$

并由 $\theta_p(x)$ 的构造中可以看出，对在可行域中的点 x^* ，一定有 $\theta_p(x^*) = f(x^*)$ 。

因此

$$\min_x L(x, \alpha, \beta) \leq \max_{\alpha, \beta, \alpha_i \geq 0} L(x^*, \alpha, \beta) \quad (60)$$

也就是说

$$\theta_d(\alpha, \beta) \leq \theta_p(x^*) \quad (61)$$

由于左边是关于参数的函数，右边是关于自变量的函数，从而我们可以对左边取极大，对右边取极小，得到

$$\max_{\alpha, \beta, \alpha_i \geq 0} \theta_d(\alpha, \beta) \leq \min_x \theta_p(x^*) \quad (62)$$

即对偶问题的最优解比原问题的最优解小。如果我们把原始问题的最优结果记为 p^* ，把对偶问题的最优结果记为 d^* ，那么我们就有

$$d^* \leq p^* \quad (63)$$

这个就叫做弱对偶条件。弱对偶条件在任何情况下都是成立的。

如果对某个优化问题成立 $d^* = p^*$ ，我们就说这个是强对偶条件。这里的支撑向量机问题就是一个强对偶问题。

2.4 KKT 条件

对于带不等式约束的优化问题，最优解除了满足原始约束之外，还需要满足如下条件：

$$\begin{cases} \nabla_x L(x, \alpha, \beta) &= 0 \\ h_j(x) &= 0 \\ c_i(x) &\leq 0 \\ \alpha_i &\geq 0 \\ \alpha_i c_i(x) &= 0 \end{cases} \quad (64)$$

这组条件称为 KKT 条件。其中：

- 第一条称为驻点条件（stationarity）
- 第二、三条称为原始可行性（primal feasibility）
- 第四条称为对偶可行性（dual feasibility）
- 最后一条称为互补松弛条件（complementary slackness）

在凸优化问题中，当满足适当条件时（例如 Slater 条件），原问题与对偶问题满足强对偶性，此时 KKT 条件也是最优解的充分必要条件。

2.5 强对偶与 KKT 条件的联系

我们来说明，强对偶成立时，KKT 条件是如何自然冒出来的。

假设强对偶成立，即 $d^* = p^*$ ，设 (x^*, α^*, β^*) 分别是原始问题与对偶问题的最优解。考虑如下不等式链：

$$\underbrace{\theta_d(\alpha^*, \beta^*)}_{=d^*} = \min_x L(x, \alpha^*, \beta^*) \leq L(x^*, \alpha^*, \beta^*) \leq \theta_p(x^*) = \underbrace{\min_x \theta_p(x)}_{=p^*} \quad (65)$$

由于 $d^* = p^*$ ，这条链两端相等，中间所有的 $\leq$ 都必须取等。这两个等号各自给出一个条件。

第一个等号： $\min_x L(x, \alpha^*, \beta^*) = L(x^*, \alpha^*, \beta^*)$

这说明 x^* 是 $L(\cdot, \alpha^*, \beta^*)$ 关于 x 的极小值点，于是驻点条件成立：

$$\nabla_x L(x^*, \alpha^*, \beta^*) = 0 \quad (66)$$

第二个等号： $L(x^*, \alpha^*, \beta^*) = f(x^*)$ 展开就是

$$\sum_i \alpha_i^* c_i(x^*) = 0 \quad (67)$$

其中等式约束等于 0，因为 x^* 是可行解。

由于每一项都满足 $\alpha_i^* \geq 0$ 且 $c_i(x^*) \leq 0$ ，每一项都 ≤ 0 ，它们加起来等于零，因此每一项必须单独为零：

$$\alpha_i^* c_i(x^*) = 0 \quad (68)$$

这就是互补松弛条件。其直觉是：要么约束不紧 ($c_i(x^*) < 0$)，对目标函数没有影响，此时 $\alpha_i^* = 0$ ；要么约束紧 ($c_i(x^*) = 0$)， α_i^* 可以不为零。

加上原来就有的可行性条件 $c_i(x^*) \leq 0$ ， $\alpha_i^* \geq 0$ ，合在一起就是完整的 KKT 条件。从而我们如果知道一个优化问题是强对偶的，那么他的最优解就一定满足 KKT 条件。

反过来，如果 x^* 满足 KKT 条件，我们想问它是否就是最优解呢？答案一般是否定的。只有对于凸优化问题而言，才能用满足 KKT 条件的点得到这个点就是最优解。

因此，**KKT 条件是强对偶成立时最优解必须满足的条件**，它从不等式链取等这一事实中自然导出，对于凸优化问题（如 SVM），在 Slater 条件下强对偶成立，KKT 条件也从必要条件升级为充要条件：

$$x^* \text{ 是最优解} \iff x^* \text{ 满足 KKT 条件} \quad (69)$$

2.6 对对偶问题的进一步理解

现在来说明，对偶问题的求解过程中， $\nabla_x L = 0$ 这一步究竟是什么意思。

第一层含义：求对偶函数的计算工具

$\theta_d(\alpha) = \min_{w,b} L(w, b, \alpha)$ 是对固定的 α ，把 L 关于 w, b 求极小。令 $\nabla_w L = 0$ ， $\frac{\partial L}{\partial b} = 0$ ，只是求极小值的必要条件，属于普通的微积分操作，此时还没有用到 KKT 条件，也没有用到强对偶。解出 w, b 与 α 的关系，代回 L ，得到只含 α 的 $\theta_d(\alpha)$ 。

第二层含义：还原原始最优解时的 KKT 驻点条件

解对偶问题得到最优 α^* 后，我们需要从 α^* 还原出原始问题的 w^* 。由于 SVM 满足强对偶，最优解满足 KKT 条件，驻点条件给出：

$$\nabla_w L(w^*, b^*, \alpha^*) = 0 \quad (70)$$

这个式子与第一步求极小时的形式完全相同，因此第一步解出的关系式

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (71)$$

代入最优 α^* 后，直接给出原始最优解 w^* 。

两层含义形式相同，含义不同。能用同一个式子做两件事，正是强对偶成立的结果。

2.7 求解对偶问题

前面已经得到拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) \quad (72)$$

其中 $\alpha_i \geq 0$ 。这里的参数是 α ，自变量是 w 和 b 。

延续上文，我们定义

$$\theta_d(\alpha) = \min_{w, b} L(w, b, \alpha) \quad (73)$$

并利用对偶问题的解来求原问题的解。为了求 $\theta_d(\alpha)$ 的表达式，令 L 对 w 和 b 的偏导为零

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad (74)$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (75)$$

于是得到

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (76)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (77)$$

将这两个结果代回 L ，第一项 $\frac{1}{2}\|w\|^2$ 变成

$$\frac{1}{2} \left(\sum_{i=1}^N \alpha_i y_i x_i \right) \cdot \left(\sum_{j=1}^N \alpha_j y_j x_j \right) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (78)$$

第三项 $\sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b)$ 变成

$$\sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) = \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_j \cdot x_i) + b \sum_{i=1}^N \alpha_i y_i \quad (79)$$

由 $\sum_{i=1}^N \alpha_i y_i = 0$ 知第二项为零，而第一项与前面的 $\frac{1}{2}\|w\|^2$ 合并，得到

$$\theta_d(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (80)$$

于是对偶问题就是

$$\max_{\alpha} \theta_d(\alpha) \quad (81)$$

约束条件为

$$\sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0 \quad (82)$$

转化为标准优化问题就是

$$\begin{array}{ll}
 \min_{\alpha} & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\
 \text{s.t.} & \sum_{i=1}^N \alpha_i y_i = 0 \\
 & \alpha_i \geq 0
 \end{array} \tag{83}$$

这就是 SVM 的对偶形式。

3 从对偶问题重新回到原问题

对最优化问题

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (84)$$

$$\begin{aligned} \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0 \end{aligned} \quad (85)$$

也被我们称为是硬间隔的问题，我们需要求解以 α 为自变量的目标函数并最终利用 KKT 条件得到关于 w 与 b 的式子。前文我们只讨论了对偶问题的解，并没有仔细说如何把对偶问题的解转化为原问题的解。这篇我们需要做两件事情，一是如何类比感知机的方法，利用梯度下降法的思想求解原始问题。二是如何通过求解使得对偶问题有最优解的 α 转化为使原问题有最优解的 w, b 。

因为目标函数中

$$y_i y_j (x_i \cdot x_j) \quad (86)$$

仅与训练数据有关，而与优化变量 α 无关，因此我们可以预先把这一部分计算出来。

数据集 X 是 $N \times d$ 的矩阵，标签 y 是 $N \times 1$ 的列向量，考虑

$$G_x = X X^T \quad (87)$$

是数据的 Gram 矩阵，而

$$G_y = y y^T \quad (88)$$

给出了标签之间的符号关系矩阵。令

$$G = G_x \circ G_y \quad (89)$$

是矩阵的 Hadamard 乘积，于是我们就得到了目标函数右侧的那一部分的矩阵。

于是目标函数变为了

$$f(\alpha) = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j G_{i,j} - \sum_{i=1}^N \alpha_i \quad (90)$$

这个本质上是二次型

$$f(\alpha) = \frac{1}{2} \alpha^T G \alpha - \sum_{i=1}^N \alpha_i \quad (91)$$

其中 G 是对称矩阵。

3.1 回到原问题

假如说我求解出的 α 是对偶问题的解。现在我们要把它转化为原问题的解。

对于原问题，由 KKT 条件可以得到

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (92)$$

这里 α 是通过计算得到的结果， x 和 y 是已知的样本数据，从而可以计算得到 w 。

而对 b 的处理就要稍微麻烦一点。可以证明 α 不为零向量，否则可以得到 $w = 0$ ，从而其作为系数诱导的分类函数 $f(x) = \text{sign}(wx + b)$ 将没有意义。因此必然存在 $\alpha_j > 0$ ，我们对这一点进行分析。由于 $\alpha_j > 0$ ，利用 KKT 条件，因为 $\alpha_j c_j(x) = 0$ ，从而不等式约束 $c_j(x)$ 变为等式约束，也就是说

$$c_j(x) = 0 \quad (93)$$

注意到

$$c_j(x) = 1 - y_j(w \cdot x_j + b) = 0 \quad (94)$$

代入 w 得到

$$1 = y_j \left(\sum_{i=1}^N \alpha_i y_i (x_i \cdot x_j) + b \right) \quad (95)$$

并且由于 $y_j^2 = 1$ ，所以

$$\begin{aligned} b &= y_j - \sum_{i=1}^N \alpha_i y_i (x_i \cdot x_j) \\ &= y_j \left(1 - \sum_{i=1}^N \alpha_i G_{i,j} \right) \end{aligned} \quad (96)$$

或者我们直接从 $c_j(x) = 0$ 推出

$$b = y_i (1 - w \cdot x_j) \quad (97)$$

也可以。

这样就得到了原问题的解。

3.2 一个看似可行的思路

现在关键的问题是，我们如何在约束

$$\sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0 \quad (98)$$

下求出极值？这里就要引入利用投影的梯度下降法。我们仍然是对 f 求梯度，得到

$$\nabla f = G\alpha - \mathbf{1} \quad (99)$$

由于函数梯度的方向指向其函数值增大的方向，所以我们要沿着其反方向做参数的更新。设学习率 η ，从而

$$\alpha^{\text{new}} = \alpha - \eta \nabla f \quad (100)$$

但是会导致我们不一定能够满足约束条件中的等式约束和不等式约束了。这怎么办呢？这里有两种思路。

3.2.1 思路一

对于不等式约束，我们强制对每一个 α_i 取正值，令

$$\alpha^{\text{pos}} = \max\{\alpha, 0\} \quad (101)$$

对于等式约束，我们考虑向量在超平面上的投影向量。

$$\alpha_{\parallel} = \alpha^{\text{pos}} - \frac{y^T \alpha^{\text{pos}}}{y^T y} y \quad (102)$$

3.2.2 思路二

我们先满足等式约束，我们考虑向量在超平面上的投影向量。

$$\alpha_{\parallel} = \alpha - \frac{y^T \alpha}{y^T y} y \quad (103)$$

再考虑不等式约束，我们强制对每一个分量取正值，令

$$\alpha^{\text{pos}} = \max\{\alpha_{\parallel}, 0\} \quad (104)$$

上述过程几何意义其实非常直观。梯度下降会让参数沿着目标函数下降最快的方向移动，但这个方向可能会离开约束平面。这里我们进行了两种投影方式，第一种是先满足不等式约束再满足等式约束，第二种是先满足等式约束再满足不等式约束。

$$\begin{aligned} G_x &= X X^T \\ G_y &= y y^T \\ G &= G_x \circ G_y \\ f(\alpha) &= \frac{1}{2} \alpha^T G \alpha - \mathbf{1}^T \alpha \\ \nabla f(\alpha) &= G \alpha - \mathbf{1} \\ \alpha &= \text{project}(\alpha) \\ w &= \sum_{i=1}^N \alpha_i y_i x_i \\ b &= y_j (1 - w \cdot x_j), \quad \alpha_j > 0 \end{aligned} \quad (105)$$

这个过程看上去可行，其实是有不少漏洞。例如算法的收敛性证明，学习率的选择，包括两种不同投影顺序的区别，这些都要仔细考察。

因为我们想一次性处理所有的向量参数，但同时又要满足两个约束，这是不能做到的。我们只能做到满足其中一个约束。这也是为什么我们需要引入新的迭代算法例如 SMO 等等。

不过我们还是可以分析一下两种算法哪一个更合理，以及学习率和收敛性的简单解释。

3.3 关于学习率和收敛性

考虑这样一个数据集， $X = \{(x_{i,1}, x_{i,2})\}$ 和 $y = \{y_i : y_i^2 = 1\}$ 。我们定义

$$\|A\| = \sqrt{\sum_{i=1}^M \sum_{j=1}^N a_{ij}^2} \quad (106)$$

表示 Frobenius 范数。一个简单的结论是

$$\|A \cdot B\| \leq \|A\| \|B\| \quad (107)$$

它可以用柯西不等式证明。由上面的过程，我们分别计算 G_x 和 G_y ，利用不等式可以得到

$$\|G_x\| = \|XX^T\| \leq \|X\| \|X^T\| = \|X\|^2 \quad (108)$$

类似地，

$$\|G_y\| \leq \|y\|^2 = N \quad (109)$$

设

$$\|X\| \leq M \quad (110)$$

因为矩阵 G 是 G_x 与 G_y 的 Hadamard 积，并且 G_y 中的元素均为 ± 1 ，从而

$$\|G\| = \|G_x\| \leq M^2 \quad (111)$$

下面关键是对学习率和收敛性的综合考量。详见下一章节的分析。

3.4 关于两个投影方法的比较

通过计算机实验可以发现，最后一步选择投影到正数是更好的。这其实隐含一个关键信息，支撑向量是一个很关键的概念。我们必须强制让 $\alpha > 0$ 。

3.5 投影公式的简单证明

由于约束

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (112)$$

可以写成

$$y^T \alpha = 0 \quad (113)$$

而这就是一个超平面，在 2 维空间中体现为一条直线，在 3 维空间中体现为一个平面。

对于向量 α^{pos} ，我们考虑其在超平面上的投影公式。这里简单证明一下。

考虑超平面

$$y^T \alpha = 0 \quad (114)$$

其中 y 是该超平面的法向量。因此我们可以把 α^{pos} 分解为

$$\alpha^{\text{pos}} = \alpha_{\parallel} + \alpha_{\perp} \quad (115)$$

其中：

- $\alpha_{\parallel}$ 平行于超平面，也就是落在超平面内部；
- $\alpha_{\perp}$ 垂直于超平面，也就是沿着法向量 y 的方向。

由于法向量方向唯一，因此存在某个实数 λ 使得

$$\alpha_{\perp} = \lambda y \quad (116)$$

于是

$$\alpha^{\text{pos}} = \alpha_{\parallel} + \lambda y \quad (117)$$

因为 $\alpha_{\parallel}$ 在超平面上，所以满足

$$y^T \alpha_{\parallel} = 0 \quad (118)$$

对上式两边左乘 y^T 得到

$$y^T \alpha^{\text{pos}} = y^T \alpha_{\parallel} + \lambda y^T y \quad (119)$$

由 $y^T \alpha_{\parallel} = 0$ 可得

$$y^T \alpha^{\text{pos}} = \lambda y^T y \quad (120)$$

因此

$$\lambda = \frac{y^T \alpha^{\text{pos}}}{y^T y} \quad (121)$$

从而垂直分量为

$$\alpha_{\perp} = \frac{y^T \alpha^{\text{pos}}}{y^T y} y \quad (122)$$

因此其在超平面上的投影为

$$\alpha_{\parallel} = \alpha^{\text{pos}} - \frac{y^T \alpha^{\text{pos}}}{y^T y} y \quad (123)$$

这个也是我们更新参数的目标。于是对参数 α , 首先我们进行梯度下降法 $\alpha^{\text{new}} = \alpha - \eta \nabla f$, 接着剔除负数, 令 $\alpha^{\text{pos}} = \max\{\alpha, 0\}$, 最后将它投影在超平面上。令

$$\alpha_{\parallel} = \alpha^{\text{pos}} - \frac{y^T \alpha^{\text{pos}}}{y^T y} y \quad (124)$$

就得到最终结果。

4 引理一：线性变换的收缩性

设 $G \in \mathbb{R}^{N \times N}$ 是实对称半正定矩阵，特征值 $\lambda_1, \dots, \lambda_N \geq 0$ ，记 $\lambda_{\max} = \max_i \lambda_i$ 。定义线性变换

$$F(x) = (I - \eta G)x, \quad (125)$$

其中步长 $\eta \geq 0$ 。则对任意 $x, y \in \mathbb{R}^N$ 有

$$\|F(x) - F(y)\| \leq \|x - y\| \quad (126)$$

当且仅当

$$\eta \leq \frac{2}{\lambda_{\max}} \quad (\text{当 } \lambda_{\max} = 0 \text{ 时理解为无上界, 即任意 } \eta \geq 0 \text{ 均成立}). \quad (127)$$

证明. 令 $v = x - y$ ，由线性性得 $F(x) - F(y) = (I - \eta G)v$ 。要证的不等式等价于

$$\|(I - \eta G)v\|^2 \leq \|v\|^2, \quad \forall v \in \mathbb{R}^N. \quad (1)$$

因为 G 实对称，存在正交矩阵 P 使

$$G = P^T D P, \quad D = \text{diag}(\lambda_1, \dots, \lambda_N). \quad (128)$$

于是

$$I - \eta G = P^T (I - \eta D) P. \quad (129)$$

作正交变换 $u = Pv$ ，则 $\|u\| = \|v\|$ ，且

$$\|(I - \eta G)v\|^2 = \|P^T (I - \eta D)u\|^2 = \|(I - \eta D)u\|^2 = \sum_{i=1}^N (1 - \eta \lambda_i)^2 u_i^2. \quad (2)$$

充分性： 设 $0 \leq \eta \leq 2/\lambda_{\max}$ (当 $\lambda_{\max} = 0$ 时 η 任意非负)。对每个 i ，由 $\lambda_i \in [0, \lambda_{\max}]$ 得 $0 \leq \eta \lambda_i \leq 2$ ，从而 $|1 - \eta \lambda_i| \leq 1$ ， $(1 - \eta \lambda_i)^2 \leq 1$ 。代入 (2) 得

$$\|(I - \eta G)v\|^2 \leq \sum_{i=1}^N u_i^2 = \|u\|^2 = \|v\|^2, \quad (130)$$

即 (1) 成立，收缩性得证。

必要性： 设 (1) 对一切 $v \in \mathbb{R}^N$ 成立。因为 $u = Pv$ 遍历 $\mathbb{R}^N$ ，(1) 与 (2) 给出

$$\sum_{i=1}^N (1 - \eta \lambda_i)^2 u_i^2 \leq \sum_{i=1}^N u_i^2, \quad \forall u \in \mathbb{R}^N. \quad (131)$$

取标准基向量 $u = e_j$ (第 j 个分量为 1，其余为 0)，得

$$(1 - \eta\lambda_j)^2 \leq 1, \quad j = 1, \dots, N. \quad (132)$$

故 $|1 - \eta\lambda_j| \leq 1$, 即 $-1 \leq 1 - \eta\lambda_j \leq 1$. 移项得 $0 \leq \eta\lambda_j \leq 2$. 因为对所有 j 成立, 特别地对最大特征值 $\lambda_{\max}$ 有 $\eta\lambda_{\max} \leq 2$. 当 $\lambda_{\max} > 0$ 时, 即得 $\eta \leq 2/\lambda_{\max}$; 当 $\lambda_{\max} = 0$ 时, 条件 $0 \leq \eta\lambda_j \leq 2$ 自动满足, 对 $\eta \geq 0$ 无额外限制. 必要性得证。

综上, 引理成立。■

□

注记 4.1. 原问题是对目标函数

$$f(\alpha) = \frac{1}{2}\alpha^T G \alpha - \alpha \quad (133)$$

在等式约束和不等式约束下求解极小值。如果我们计算梯度

$$\nabla f(\alpha) = G\alpha - \mathbf{1} \quad (134)$$

就能得到利用梯度下降法得到的递推式

$$\begin{aligned} \alpha_{k+1} &= \alpha_k - \eta \nabla f(\alpha) \\ &= (I - \eta G)\alpha_k + \eta \end{aligned} \quad (135)$$

是一个仿射变换, 即 $\alpha_{k+1} = F(\alpha_k)$, 其中 $F(\alpha) = (I - \eta G)\alpha + \eta$.

结合 $\|F(x) - F(y)\| = \|(I - \eta G)(x - y)\|$, 我们利用上面的引理可以得到可以选择合适的 η 使得 $\|F(x) - F(y)\| \leq \|x - y\|$. 这能保证 $\{\alpha_k\}$ 是有界的。尽管其收敛性只有在 F 是线性变换才能利用 Browder 不动点定理给出一个合理的解释, 但是由于实际模拟中 η 的取值往往非常小, 所以也能得到相对好的精度。

注记 4.2. 由于特征值比较难算, 所以我们可以利用范数不等式 $\|A \cdot B\| \leq \|A\| \|B\|$, 考虑实对称半正定矩阵 A 的特征向量 x 以及特征值 $\lambda \geq 0$, 从而有

$$\begin{aligned} \|Ax\| &= \|\lambda x\| = \lambda \|x\| \\ &\leq \|A\| \|x\| \end{aligned} \quad (136)$$

因此 $\lambda \leq \|A\|$. 从而当

$$0 \leq \eta \leq \frac{2}{\|G\|} \leq \frac{2}{\lambda_{\max}} \quad (137)$$

时, 我们也能得到

$$\|F(x) - F(y)\| \leq \|x - y\| \quad (138)$$

的结论。这在机器学习和感知机里面是一个相对重要的结果, 在一些学习率的收敛性估计中需要用到。

5 投影梯度法的收敛性与稳定点严格证明

为了严格分析算法的收敛性，我们首先将一轮迭代中的三个递推步骤统一写成一个复合算子 $T: \mathbb{R}^N \rightarrow \mathbb{R}^N$ 。

对于空间中任意一个初始参数 α_{k-1} ，算法的单步更新步骤为：

第 1 步： 梯度下降步 F ：

$$\beta_k = F(\alpha_{k-1}) = \alpha_{k-1} - \eta(G\alpha_{k-1} - \mathbf{1}) \quad (139)$$

其中可以令

$$F(x) = (I - \eta G)x + \eta \mathbf{1} \quad (140)$$

其中这里的 G 是半正定矩阵。

第 2 步： 等式投影步 P_H ：

$$\gamma_k = P_H(\beta_k) = \beta_k - \frac{1}{N}yy^T\beta_k \quad (141)$$

第 3 步： 非负截断步 P_+ ：

$$\alpha_k = P_+(\gamma_k) = \max\{\gamma_k, 0\} \quad (142)$$

整个复合迭代算子表示为： $\alpha_k = T(\alpha_{k-1}) = (P_+ \circ P_H \circ F)(\alpha_{k-1})$ 。

5.1 第一部分：全局非扩张性证明（Non-expansiveness）

我们首先证明，对于空间中任意两个向量 $x, y \in \mathbb{R}^N$ ，算子 T 满足非扩张性，即 $\|T(x) - T(y)\| \leq \|x - y\|$ 。在这个证明过程中，我们不依赖任何关于稳定点或收敛性的假设。

5.1.1 1. 梯度步的距离变化（引用引理一）

我们首先利用引理一证明

$$\|F(x) - F(y)\| \leq \|x - y\| \quad (143)$$

是成立的。又因为矩阵的最大特征值满足： $\lambda_{\max}(G) \leq \|G\| \leq M^2$ 。因此，我们选择学习率满足：

$$\boxed{\eta \leq \frac{2}{M^2}} \quad (144)$$

这严格保证了梯度步的非扩张性成立：

$$\boxed{\|F(x) - F(y)\| \leq \|x - y\|} \quad \dots(\text{式 A}) \quad (145)$$

5.1.2 2. 等式投影步的距离变化

令 $v_x = F(x)$, $v_y = F(y)$ 。将投影后的向量相减:

$$P_H(v_x) - P_H(v_y) = (v_x - v_y) - \frac{1}{N}yy^T(v_x - v_y) \quad (146)$$

为了代数书写简便, 令向量 $w = v_x - v_y$, 上式化为:

$$P_H(v_x) - P_H(v_y) = w - \frac{y^T w}{N}y \quad (147)$$

计算其模长平方 (展开二次型):

$$\begin{aligned} \|P_H(v_x) - P_H(v_y)\|^2 &= \left(w - \frac{y^T w}{N}y\right)^T \left(w - \frac{y^T w}{N}y\right) \\ &= w^T w - \frac{2(y^T w)}{N}(y^T y)^T w + \frac{(y^T w)^2}{N^2}(y^T y) \end{aligned} \quad (148)$$

因为 $y^T y = N$, 最后一项的分母消去一个 N , 代数式简化为:

$$= \|w\|^2 - \frac{2}{N}(y^T w)^2 + \frac{1}{N}(y^T w)^2 = \|w\|^2 - \frac{(y^T w)^2}{N} \quad (149)$$

由于 $\frac{(y^T w)^2}{N} \geq 0$, 代回 w 得到:

$$\boxed{\|P_H(v_x) - P_H(v_y)\|^2 \leq \|v_x - v_y\|^2} \quad \dots(\text{式 B}) \quad (150)$$

5.1.3 3. 非负截断步的分量对比

令 $u_x = P_H(v_x)$, $u_y = P_H(v_y)$ 。对比截断后各分量的平方差:

$$(P_+(u_x)_i - P_+(u_y)_i)^2 = (\max\{u_{x,i}, 0\} - \max\{u_{y,i}, 0\})^2 \quad (151)$$

我们利用一维实数轴上的距离关系, 验证不等式 $(\max\{a, 0\} - \max\{b, 0\})^2 \leq (a - b)^2$ 的正确性:

- 情况一: 若 $a \geq 0, b \geq 0$, 不等式取等号。
- 情况二: 若 $a < 0, b < 0$, 左边为 0, 右边为 $(a - b)^2 \geq 0$, 不等式显然成立。
- 情况三: 若 $a \geq 0, b < 0$, 左边为 a^2 。而右边为 $(a - b)^2 = (a + |b|)^2 > a^2$, 不等式严格成立。

将所有分量相加, 可得向量模长不等式:

$$\boxed{\|P_+(u_x) - P_+(u_y)\|^2 \leq \|u_x - u_y\|^2} \quad \dots(\text{式 C}) \quad (152)$$

5.1.4 4. 复合算子的全局非扩张结论

将式 A、式 B、式 C 顺次相连，我们证明了对空间中任意两个向量 $x, y \in \mathbb{R}^N$ ：

$$\|T(x) - T(y)\|^2 \leq \|P_H(F(x)) - P_H(F(y))\|^2 \leq \|F(x) - F(y)\|^2 \leq \|x - y\|^2 \quad (153)$$

由此，我们严格地证明了复合迭代算子 T 满足全局非扩张性：

$$\boxed{\|T(x) - T(y)\| \leq \|x - y\| \quad (\forall x, y \in \mathbb{R}^N)} \quad (154)$$

5.2 第二部分：稳定点（不动点） α^* 的存在性定理

在第一部分完全不依赖任何稳定点假设的前提下，我们已经确立了算子 T 的全局非扩张性。现在，我们引入非线性分析中的经典不动点定理：

定理一：Browder 不动点定理

设 $C \subset \mathbb{R}^N$ 是一个闭凸集，且映射 $T : C \rightarrow C$ 满足全局非扩张性。若迭代序列 $\{T^k(x_0)\}$ 有界，则算子 T 在 C 上必定存在至少一个不动点 α^* ，使得：

$$\alpha^* = T(\alpha^*) \quad (155)$$

但是，很可惜，我们的映射 T 不满足这个性质。也就是说我们没法使用这个定理。我们只能证明存在稳定点，不能证明收敛性。

因此，由定理一，算法稳定点 α^* 的存在性在数学上被严格确立。它满足：

$$\beta^* = \alpha^* - \eta(G\alpha^* - \mathbf{1}) \quad (156)$$

$$\gamma^* = \beta^* - \frac{1}{N}yy^T\beta^* \quad (157)$$

$$\alpha^* = \max\{\gamma^*, 0\} \quad (158)$$

5.3 第三部分：算法收敛性的严格证明（存疑）

既然稳定点 α^* 的存在性已仍然无法得知，我们现在只能假设存在稳定点。实际上，利用 Bolzano-Weierstrass 定理，我们知道必然存在收敛点列，尽管不一定是最优解。我们现在来证明迭代序列 $\{\alpha_k\}$ 必定收敛于该点。

在第一部分已证的全局非扩张不等式中：

$$\|T(x) - T(y)\| \leq \|x - y\| \quad (\forall x, y \in \mathbb{R}^N) \quad (159)$$

因为这一不等式对空间中任意两个向量都成立，我们现在将 x 特化为第 $k-1$ 步的迭代点 α_{k-1} ，将 y 特化为已证实存在的稳定点 α^* 。代入上式得到：

$$\|T(\alpha_{k-1}) - T(\alpha^*)\| \leq \|\alpha_{k-1} - \alpha^*\| \quad (160)$$

根据定义, 有 $\alpha_k = T(\alpha_{k-1})$, 且 $T(\alpha^*) = \alpha^*$ 。代入上式直接得到:

$$\boxed{\|\alpha_k - \alpha^*\| \leq \|\alpha_{k-1} - \alpha^*\|} \quad (161)$$

结论:

1. 几何距离序列 $d_k = \|\alpha_k - \alpha^*\|$ 是一个**单调递减且有下界** (≥ 0) 的实数序列。根据实数域的单调有界原理, 距离序列 d_k 必定收敛。
2. 结合算子的平均性质, 这严格证明了算法序列 $\{\alpha_k\}$ 必定收敛于稳定点 α^* 。■